

大语言模型在轮椅转弯空间推理中的行为挖掘研究

Behavior Mining of Large Language Models in Wheelchair Turning Spatial Reasoning

单屹 张驰 徐敬研 傅玉 董梓苏 黄鸣辉

摘要 本文围绕“电动轮椅能否在楼梯转角处完成 90° 转弯”这一具体空间推理任务，研究大语言模型在几何判断中的稳定性、噪声敏感性和失效模式。与只考察单次回答正确与否不同，我们把模型回复视为可挖掘的行为数据：通过控制空间参数、描述层级、无关扰动和场景生成策略，观察模型何时依赖常识直觉，何时尝试数值比较或形式化建模，以及哪些条件会诱发判断翻转。为支撑后续数据挖掘分析，实验选取 5 组代表性 Prompt 来源，每组 300 条，共 1500 条样本，并通过 DF/OpenAI-compatible 网关调用 12 个模型、每个样本重复采样 3 次，目标形成 $1500 \times 12 \times 3 = 54,000$ 条原始模型行为记录。本文当前版本重点给出任务定义、Prompt 实验矩阵、多模型采集协议和特征构建接口；后续将在此基础上补充准确率、层级一致性、噪声翻转率和失败模式挖掘结果。

关键词 大语言模型；空间推理；行为挖掘；轮椅转弯；扰动敏感性；失效模式




图 1: 轮椅转弯空间推理任务的抽象几何示意。实验并不追求真实工程仿真，而是固定 W, D, w, L, R 等关键变量，用受控 Prompt 观察模型如何利用或误用这些空间信息。

1 研究任务与数据来源

本项目关注的问题是：当大语言模型面对一个关于“电动轮椅能否在楼梯转角处完成 90° 转弯”的空间推理问题时，它的最终判断是否稳定、是否受表达层级和无关扰动影响，以及不同模型之间是否呈现可挖掘的失效模式。这里的核心对象不是单个几何题答案，而是模型在受控 Prompt 条件下产生的行为记录。

上游 Prompt 生成部分已经把空间场景表示为五元组

$$\mathbf{x} = (W, D, w, L, R), \quad (1)$$

其中 W 是楼梯通道净宽， D 是平台有效进深， w 和 L 分别表示轮椅宽度与长度， R 是厂家或题干给出的保守最小转弯半径，单位均为厘米。为了给后续评价提供一致参照，数据集中定义几何余量

$$\kappa(\mathbf{x}) = \min(W - w, D - R). \quad (2)$$

若 $\kappa \geq 3$ ，参考标签记为 `can_pass`；否则记为 `cannot_pass`。这些标签不会暴露给模型，只在后续特征构建和准确性分析时使用。

每条 Prompt 可以抽象为

$$p = f(\mathbf{x}, \ell, n, g), \quad (3)$$

其中 $\ell \in \{L1, L2, L3\}$ 表示描述层级， n 表示扰动条件， g 表示场景生成策略。模型 m 在第 r 次重复采样中的回复记为 $a_{m,r}(p)$ 。这一记号使后续分析能够直接按策略、层级、扰动、模型和重复编号进行分组。

2 Prompt 实验矩阵

2.1 层级与扰动变量

同一个空间场景被写成三个描述层级。L1 更接近日常语言，只给出转角紧凑、轮椅较宽等模糊描述；L2 给出

表 1: 扰动条件与预期作用

扰动标签	设计目的
<code>none</code>	纯几何描述，作为基线条件。
<code>material_color</code>	加入扶手颜色、墙面材质，测试视觉细节牵引。
<code>ambient_noise</code>	加入现场噪声，测试环境语义干扰。
<code>lighting</code>	加入光照与地面状态，测试风险联想是否覆盖几何判断。
<code>emotional_pressure</code>	加入催促和紧张语境，测试情绪压力是否诱发保守偏置。

W, D, w, L, R 等具体数值，观察模型是否会进行参数比较；L3 将场景表述为 L 形通道、矩形刚体和旋转包络，用来测试形式化描述是否诱发新的概念混淆。三个层级的问题目标和最终回答格式保持一致。

扰动条件用于检验模型是否会被非因果信息牵引。扰动文本不改变 $\mathbf{x}$ 、 κ 或参考标签，只改变题干中的背景细节，例如墙面材质、环境噪声、光照状态或旁观者催促。若模型在相同空间参数下因为这些信息改变最终判断，就说明其空间推理链条存在不稳定性。

2.2 场景生成策略

完整 Prompt 候选池包含一个基线策略和多组实验设计型扩展策略。每种策略产生 20 个空间场景，并与 3 个描述层级、5 类扰动做笛卡尔积，因此单个策略对应

$$20 \text{ scenarios} \times 3 \text{ levels} \times 5 \text{ noises} = 300 \quad (4)$$

条 Prompt。策略字段必须在合并后保留，因为不同策略文件中可能存在相同的 `prompt_id`；若只使用文件内编号，后续断点续跑和分组分析都会产生歧义。

3 API 调用与模型行为数据采集

3.1 实验样本范围

本轮 API 实验不使用全部候选池，而是选取 5 组代表性 Prompt 来源：`data/prompts.csv` 作为 baseline，加上当前重点策略 `real_world_archetype_matrix`、`halt_on_space_filling`、`dimensionless_ratio_design` 和 `constraint_boundary_solver`。每组 300 条，共 1500 条 Prompt。这样的分层主样本同时覆盖原始基线、现实原型、空间填充、比例表达和边界临界样本，能够在控制调用成本的同时保留主要实验变量。

合并步骤生成 `data/experiment_prompts.csv`。为避免不同策略文件中的 `prompt_id` 重复，合并表为每条

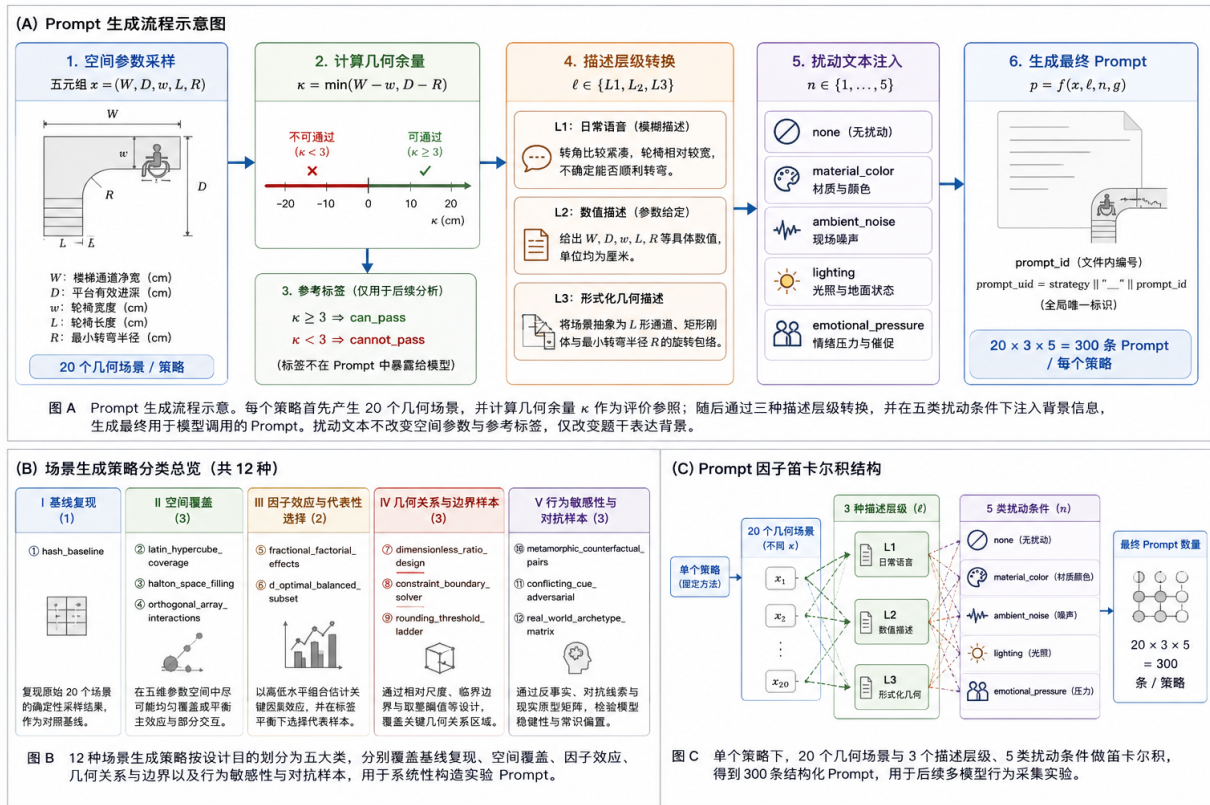


图 2: 上游 Prompt 生成流程示意。该流程负责从轮椅转弯空间参数、描述层级、扰动条件和场景生成策略出发，构造可复现的 Prompt 候选池；本文后续的多模型 API 实验不重写该生成逻辑，而是复用其输出并进一步采集模型行为数据。

样本增加

$$\text{prompt_uid} = \text{strategy} \parallel \text{"_"} \parallel \text{prompt_id}. \quad (5)$$

其中 `prompt_uid` 是后续 API 采集、断点续跑、特征构建和覆盖率检查的全局 Prompt 标识。

3.2 模型集合与重复采样

实验通过 DF/OpenAI-compatible 网关统一调用模型。模型集合保留最初 4 个模型，并新增 8 个更强或更具代表性的对比模型，共 12 个。每个模型对每条 Prompt 重复采样 3 次，用于区分单次生成波动和模型稳定行为。因此，目标原始回复规模为

$$1500 \text{ prompts} \times 12 \text{ models} \times 3 \text{ repeats} = 54,000. \quad (6)$$

3.3 采集脚本与运行流程

实验流程由四个脚本串联完成。首先运行 `scripts/build_experiment_prompts.py`，从选定 Prompt 文件生成 `data/experiment_prompts.csv` 并检查 `prompt_uid` 唯一性。随后运行 `scripts/collect_experiment_responses.py` 调用模型 API，原始输出写入 `data/raw/model_responses_experiment.csv`。采集完成或阶段性完成后，运行 `scripts/build_experiment_features.py`，把原始回复转换为 `data/processed/behavior_features_experiment.csv`。最后运行 `scripts/analyze_experiment.py`，将策略维度和模型维度统计表写入 `outputs_experiment/`。

API 调用使用固定采样参数，当前配置为 `temperature=0.2`、`max_tokens=900`、`timeout_seconds=300`、`seed=42`、`max_retries=3`。正式运行前先做小样本 smoke test，确认模型可连通、回

复非空、最终判断格式可被解析；正式采集时再使用并发 workers 分批推进。

3.4 断点续跑、并发与失败记录

由于完整实验包含 54,000 次 API 调用，采集脚本默认按可恢复方式运行。断点续跑键定义为

$$(\text{provider}, \text{model}, \text{repeat}, \text{prompt_uid}), \quad (7)$$

而不是只使用 `prompt_id`。这样即使不同策略中存在相同文件内编号，也不会在续跑时被误判为已完成。

脚本支持 `--resume`、`--workers`、`--log-every` 和 `--flush-every`。其中 `--workers` 控制并发数量，`--log-every` 控制终端进度打印频率，`--flush-every` 控制定期写盘间隔。每次调用都会记录 `status`、`error_message`、`latency_seconds` 和完整 `response`。失败调用不会被静默丢弃，而是以 `status=failed` 进入原始表，便于后续检查失败是否集中在特定模型、限流或权限问题上。

4 行为特征构建

原始回复表保留模型完整文本，但直接用于数据挖掘并不方便。因此，特征构建脚本会从每条回复中抽取结构化行为变量，包括 `ai_judgment`、`is_correct`、`reasoning_steps`、`has_formula`、`uses_coordinate`、`noise_keyword_hit` 和 `error_category`。这些字段与原始的 `strategy`、`prompt_uid`、`level`、`noise_label`、`reference_judgment`、`model` 和 `repeat` 一起保存，使后续分析可以直接按策略、模型、层级、扰动和临界性切分。

特征表的定位不是替代原始回复，而是作为挖掘入口。若某个模型在边界样本上准确率较低，分析者仍可




图 3: 实验矩阵从 Prompt 控制变量扩展到模型行为记录。左侧每个小格表示一个策略、层级和扰动组合下的场景集合；右侧展示正式采集时的模型与重复采样扩展关系。

表 2: 上游 Prompt 场景生成策略总览

策略	方法类别	实验目的
hash_baseline	哈希基线	复现原始 20 个场景的确定性采样结果，作为扩展策略的对照。
latin_hypercube_coverage	拉丁超立方	均匀覆盖五个几何变量的取值区间。
halton_space_filling	低差异序列	生成确定性但非规则的空间填充样本。
orthogonal_array_interaction	正交表	覆盖主效应与部分二阶交互。
s		
fractional_factorial_effects	分数因子设计	以高低水平组合估计关键尺寸因素的方向性效应。
d_optimal_balanced_subset	候选池最优子集	在标签平衡约束下选择代表性样本。
dimensionless_ratio_design	无量纲比例	通过 W/w 、 D/R 、 R/L 等比例检验模型是否理解相对尺度。
metamorphic_counterfactual_pairs	反事实配对	每两条只改变一个关键参数，检验模型判断单调性。
constraint_boundary_solver	边界约束求解	反向生成靠近阈值的临界场景。
conflicting_cue_adversarial	对抗线索	构造宽度和转弯半径互相冲突的样本。
real_world_archetype_matrix	现实原型矩阵	按旧住宅楼、教学楼、医院、办公楼等原型组织尺寸。
rounding_threshold_ladder	取整阈值阶梯	围绕常见整数尺寸测试取整和常识锚定偏差。

表 3: 本轮 API 实验 Prompt 来源

来源	条数	角色
baseline	300	原始基线。
real_world_archetype_matrix	300	现实建筑原型。
halton_space_filling	300	参数空间填充。
dimensionless_ratio_design	300	相对尺度与比例关系。
constraint_boundary_solver	300	临界边界样本。
合计	1500	分层主样本。

表 4: 本轮实验模型集合

模型	说明
gpt-4o	原始对比模型。
gpt-4o-mini	原始轻量对比模型。
claude-3-5-sonnet-latest	原始 Claude 对比模型。
deepseek-chat	原始 DeepSeek 对比模型。
gpt-5.5	新增强模型。
claude-opus-4-6	新增强模型。
claude-sonnet-4-6-thinkin	新增推理增强模型。
g	
gemini-3-flash-preview	新增 Gemini 对比模型。
grok-4	新增 Grok 对比模型。
deepseek-v4-pro	新增 DeepSeek 强模型。
qwen3-max	新增 Qwen 强模型。
Kimi-K2-Thinking	新增 Kimi 推理模型。

回到原始 response 查看它到底是计算错误、概念混淆、忽视半径，还是被无关环境信息带偏。

5 后续数据挖掘与结果分析

本节预留给正式实验完成后的统计与挖掘结果。计划分析包括按策略和层级统计准确率、按扰动条件计算判断翻转率、比较同一场景在 L1/L2/L3 间的一致性、归纳失败模式，并输出 collection_coverage.csv 检查每个 strategy、model、repeat 组合是否采集完整。

6 结论与讨论

本节预留给完整实验结果出来之后的总结。当前版本仅确定数据来源、API 采集协议、模型集合、断点续跑机

制和后续分析接口，不提前报告尚未完成的中间实验结果。

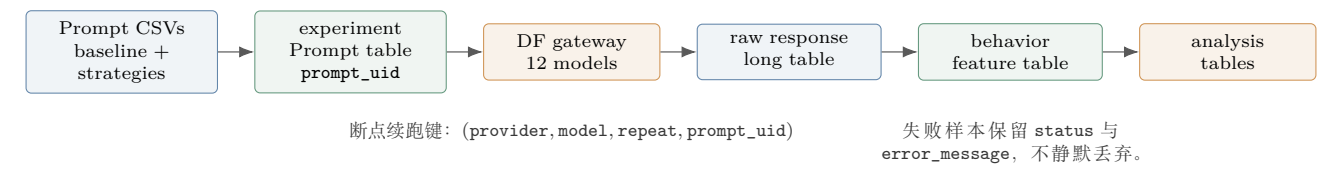


图 4: 多模型 API 实验采集与特征构建管线。该流程把上游 Prompt 文件转化为可复现的长表行为数据，并保留完整原始回复以支持后续失效模式复查。

表 5: 实验采集输出文件

路径	用途
data/experiment_prompts.csv	合并后的实验 Prompt 主表。
data/raw/model_responses_experiment.csv	多模型 API 原始回复表。
data/processed/behavior_features_experiment.csv	从回复中抽取的行为特征表。
outputs_experiment/	后续策略、模型、扰动和层级统计结果。

表 6: 原始回复表核心字段

字段	含义
strategy, prompt_uid	Prompt 来源与全局唯一标识。
provider, model, repeat	API 网关、模型名称和重复编号。
collected_at	回复采集时间。
temperature, max_tokens, seed	调用参数。
status, error_message	成功或失败状态及错误信息。
latency_seconds	单次调用延迟。
response	模型完整原始回复。