

大语言模型在轮椅转弯空间推理中的行为挖掘研究

Behavior Mining of Large Language Models in Wheelchair Turning Spatial Reasoning

单屹 张驰 徐敬研 傅玉 董梓苏 黄鸣辉

摘要 本文研究大语言模型在轮椅转弯空间推理中的行为稳定性、噪声敏感性与失效模式。我们将“电动轮椅能否在楼梯转角处完成 90° 转弯”建模为一个受控文本推理任务，把场景表示为通道净宽、平台进深、轮椅宽度、轮椅长度和最小转弯半径等几何变量，并围绕描述层级、无关扰动和场景生成策略构造 Prompt 实验矩阵。与只报告单次准确率不同，本文把模型回复视为可挖掘的行为数据：每条记录同时保留 Prompt 条件、模型、重复编号、原始回复、解析判断和失败类别，从而分析模型何时依赖常识直觉，何时尝试形式化建模，以及哪些非因果线索会诱发判断翻转。正式实验选取 5 组代表性 Prompt 来源，每组 300 条，共 1500 条样本，并通过 DF/OpenAI-compatible 网关调用 12 个模型、每个样本重复采样 3 次，形成 $1500 \times 12 \times 3 = 54,000$ 条原始模型行为记录。本文给出任务定义、相关工作、Prompt 矩阵、多模型采集协议、行为特征接口和挖掘分析框架，作为完整实验数据分析与结果解释的基础。

关键词 大语言模型；空间推理；行为挖掘；轮椅转弯；扰动敏感性；失效模式

1 引言

大语言模型已经在问答、代码、数学和常识推理等任务上表现出很强的零样本和少样本能力，但这些能力并不等价于稳定的物理空间理解。许多基准测试关注模型在静态题集上的平均准确率；对于需要落到具体环境约束的应用，更重要的问题是模型在输入表达、无关背景和临界参数变化下是否保持一致。轮椅转弯空间判断正好提供了一个小而明确的切口：题目只涉及通道净宽、平台进深、轮椅尺寸和最小转弯半径，却同时包含自然语言常识、数量比较和安全风险联想。

本文将“电动轮椅能否在楼梯转角处完成 90° 转弯”建模为一个受控行为测试任务。我们不把模型回复只看作一次答题结果，而是把它们组织成长表行为数据。每条记录同时保留 Prompt 来源、几何参数、描述层级、扰动条件、模型名称、重复编号、原始回复、解析出的最终判断和失败类别，从而支持按策略、模型、层级和噪声条件进行数据挖掘。

本文的主要贡献如下：

- 提出一个面向轮椅转弯的文本空间推理任务，把空间场景压缩为可控几何变量，并给出不暴露给模型的参考判定规则。
- 构建包含层级表达、无关扰动和多种场景生成策略的 Prompt 实验矩阵，用于区分模型的数值比较、形式化建模和常识直觉依赖。
- 设计多模型 API 采集与行为特征构建流程，支持 12 个模型、3 次重复采样、断点续跑、失败保留和挖掘分析。

正式实验包含 1500 条 Prompt、12 个模型和 3 次重复，共 54,000 条模型行为记录。本文围绕完整实验数据组织任务定义、实验协议、行为特征和分析框架，使模型比较不只停留在总体准确率，而能进一步解释策略、层级、扰动和模型族之间的行为差异。

2 相关工作

大语言模型评测。 GPT-3 的少样本学习结果表明，大规模语言模型可以通过纯文本提示完成广泛任务 [1]。随后，MMLU 和 BIG-bench 等基准进一步把评测扩展到多学科知识、常识、数学和复杂任务集合 [3, 6]。这些工作强调了跨任务能力测量的重要性，但平均分数往往难以解释模型在具体条件下为什么失败。本文选择一个更窄的空间推理场景，通过受控变量和重复采样刻画模型行为差异。

推理提示与行为测试。 Chain-of-thought prompting 说明，中间推理步骤可以显著改变模型在复杂推理任务上的表现 [7]。但可解释的推理文本并不必然代表稳定的推理过程，尤其当题干中出现无关信息或近阈值参数时，模型可能生成看似合理但结论错误的解释。CheckList 提出从行为测试角度构造能力矩阵和测试类型，避免只依赖总体准确率 [5]；对抗阅读理解工作也表明，无关或误导性文本可以显著破坏模型判断 [4]。本文借鉴这类行为测试思想，把扰动、层级和反事实条件直接纳入 Prompt 设计。

空间推理。 空间关系是人类认知和语言理解的基础。已有空间介词基准发现，大语言模型在空间关系推断上存在明显的提示敏感性和与人类表现的差距 [2]。与一般空间介词或视觉空间基准不同，本文聚焦一个纯文本、参数化、可判定的轮椅转弯任务：模型不需要识别图像，而需要在自然语言描述中提取几何约束，并判断轮椅能否完成转弯。这种任务适合观察语言模型在现实工程语境中的空间数量推理边界。

3 任务形式化与数据来源

本项目关注的问题是：当大语言模型面对一个关于“电动轮椅能否在楼梯转角处完成 90° 转弯”的空间推理问题时，它的最终判断是否稳定、是否受表达层级和无关扰动影响，以及不同模型之间是否呈现可挖掘的失效模式。这里的核心对象不是单个几何题答案，而是模型在受控 Prompt 条件下产生的行为记录。

上游 Prompt 生成部分已经把空间场景表示为五元组

$$\mathbf{x} = (W, D, w, L, R), \quad (1)$$

其中 W 是楼梯通道净宽， D 是平台有效进深， w 和 L 分别表示轮椅宽度与长度， R 是厂家或题干给出的保守最小转弯半径，单位均为厘米。为了给评价提供一致参照，数据集中定义几何余量

$$\kappa(\mathbf{x}) = \min(W - w, D - R). \quad (2)$$

若 $\kappa \geq 3$ ，参考标签记为 `can_pass`；否则记为 `cannot_pass`。这些标签不会暴露给模型，只在特征构建和准确性分析时使用。

每条 Prompt 可以抽象为

$$p = f(\mathbf{x}, \ell, n, g), \quad (3)$$

其中 $\ell \in \{L1, L2, L3\}$ 表示描述层级， n 表示扰动条件， g 表示场景生成策略。模型 m 在第 r 次重复采样中的




图 1. 轮椅转弯空间推理任务的抽象几何示意。实验并不追求真实工程仿真，而是固定 W, D, w, L, R 等关键变量，用受控 Prompt 观察模型如何利用或误用这些空间信息。

表 1. 扰动条件与预期作用

扰动标签	设计目的
none	纯几何描述，作为基线条件。
material_color	加入扶手颜色、墙面材质，测试视觉细节牵引。
ambient_noise	加入现场噪声，测试环境语义干扰。
lighting	加入光照与地面状态，测试风险联想是否覆盖几何判断。
emotional_pressure	加入催促和紧张语境，测试情绪压力是否诱发保守偏置。

回复记为 $a_{m,r}(p)$ 。这一记号使分析能够直接按策略、层级、扰动、模型和重复编号进行分组。

为了避免把问题变成开放式工程仿真，本文只使用一个保守、可复现的判定边界。该边界并不声称覆盖所有真实轮椅动力学因素，例如操作者策略、轮胎接触、平台边缘安全距离或轮椅是否支持原地旋转；它的作用是给模型行为挖掘提供一致的参照标签。当模型在相同标签下因描述方式或扰动文本而改变判断时，这种变化本身就是值得分析的行为信号。

4 Prompt 实验矩阵

4.1 层级与扰动变量

同一个空间场景被写成三个描述层级。L1 更接近日常语言，只给出转角紧凑、轮椅较宽等模糊描述；L2 给出 W, D, w, L, R 等具体数值，观察模型是否会进行参数比较；L3 将场景表述为 L 形通道、矩形刚体和旋转包络，用来测试形式化描述是否诱发新的概念混淆。三个层级的问题目标和最终回答格式保持一致。

扰动条件用于检验模型是否会被非因果信息牵引。扰动文本不改变 x, κ 或参考标签，只改变题干中的背景细节，例如墙面材质、环境噪声、光照状态或旁观者催促。若模型在相同空间参数下因为这些信息改变最终判断，就说明其空间推理链条存在不稳定性。

4.2 场景生成策略

完整 Prompt 候选池包含一个基线策略和多组实验设计型扩展策略。每种策略产生 20 个空间场景，并与 3 个

描述层级、5 类扰动做笛卡尔积，因此单个策略对应

$$20 \text{ scenarios} \times 3 \text{ levels} \times 5 \text{ noises} = 300 \quad (4)$$

条 Prompt。策略字段必须在合并后保留，因为不同策略文件中可能存在相同的 `prompt_id`；若只使用文件内编号，断点续跑和分组分析都会产生歧义。

5 API 调用与模型行为数据采集

5.1 实验样本范围

本轮 API 实验不使用全部候选池，而是选取 5 组代表性 Prompt 来源：`data/prompts.csv` 作为 baseline，加上当前重点策略 `real_world_archetype_matrix`、`halt_on_space_filling`、`dimensionless_ratio_design` 和 `constraint_boundary_solver`。每组 300 条，共 1500 条 Prompt。这样的分层主样本同时覆盖原始基线、现实原型、空间填充、比例表达和边界临界样本，能够在控制调用成本的同时保留主要实验变量。

合并步骤生成 `data/experiment_prompts.csv`。为避免不同策略文件中的 `prompt_id` 重复，合并表为每条样本增加

$$\text{prompt_uid} = \text{strategy} \parallel \text{"_"} \parallel \text{prompt_id}. \quad (5)$$

其中 `prompt_uid` 是 API 采集、断点续跑、特征构建和覆盖率检查的全局 Prompt 标识。

5.2 模型集合与重复采样

实验通过 DF/OpenAI-compatible 网关统一调用模型。模型集合保留最初 4 个模型，并新增 8 个更强或更具代表性的对比模型，共 12 个。每个模型对每条 Prompt 重复采样 3 次，用于区分单次生成波动和模型稳定行为。因此，原始回复规模为

$$1500 \text{ prompts} \times 12 \text{ models} \times 3 \text{ repeats} = 54,000. \quad (6)$$

5.3 采集脚本与运行流程

实验流程由四个脚本串联完成。首先运行 `scripts/build_experiment_prompts.py`，从选定 Prompt 文件生成 `data/experiment_prompts.csv` 并检查 `prompt_uid` 唯一性。随后运行 `scripts/collect_experiment_responses.py` 调用模型 API，原始输出写入 `data/raw/model_responses_experiment.csv`。接着运行 `scripts/build_experiment_features.py`，把原始回复转换为 `data/processed/behavior_features_experiment.csv`。最后运行 `scripts/analyze_experiment.py`，将策略维度和模型维度统计表写入 `outputs_experiment/`。

API 调用使用固定采样参数，当前配置为 `temperature=0.2`、`max_tokens=900`、`timeout_seconds=300`、`seed=42`、`max_retries=3`。正式运行前先做小样本 smoke test，确认模型可连通、回复非空、最终判断格式可被解析；正式采集时再使用并发 workers 分批推进。

5.4 断点续跑、并发与失败记录

由于完整实验包含 54,000 次 API 调用，采集脚本默认按可恢复方式运行。断点续跑键定义为

$$(\text{provider}, \text{model}, \text{repeat}, \text{prompt_uid}), \quad (7)$$

而不是只使用 `prompt_id`。这样即使不同策略中存在相同文件内编号，也不会在续跑时被误判为已完成。

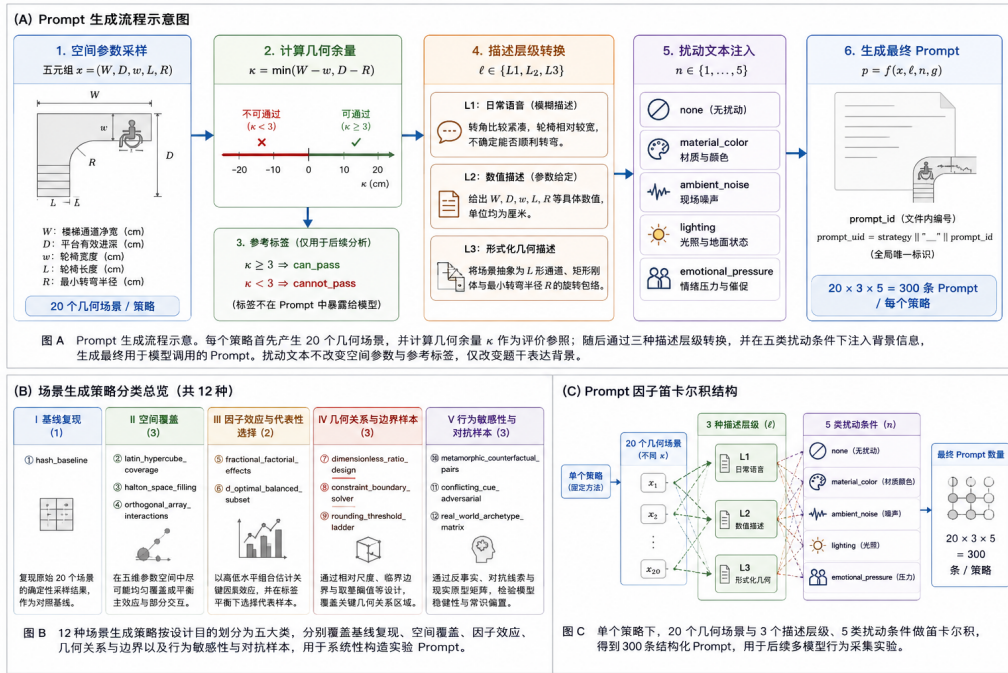


图 2. Prompt 候选池生成流程。上游模块从轮椅转弯空间参数、描述层级、扰动条件和场景生成策略出发构造可复现题目; 本文复用这些题目, 并把后续工作扩展到多模型行为采集与挖掘分析。

脚本支持 `--resume`、`--workers`、`--log-every` 和 `--flush-every`。其中 `--workers` 控制并发数量, `--log-every` 控制终端进度打印频率, `--flush-every` 控制定期写盘间隔。每次调用都会记录 `status`、`error_message`、`latency_seconds` 和完整 `response`。失败调用不会被静默丢弃, 而是以 `status=failed` 进入原始表, 便于检查失败是否集中在特定模型、限流或权限问题上。

6 行为特征构建

原始回复表保留模型完整文本, 但直接用于数据挖掘并不方便。因此, 特征构建脚本会从每条回复中抽取结构化行为变量, 包括 `ai_judgment`、`is_correct`、`reasoning_steps`、`has_formula`、`uses_coordinate`、`noise_keyword_hit` 和 `error_category`。这些字段与原始的 `strategy`、`prompt_uid`、`level`、`noise_label`、`reference_judgment`、`model` 和 `repeat` 一起保存, 使分析可以直接按策略、模型、层级、扰动和临界性切分。

特征表的定位不是替代原始回复, 而是作为挖掘入口。若某个模型在边界样本上准确率较低, 分析者仍可回到原始 `response` 查看它到底是计算错误、概念混淆、忽视半径, 还是被无关环境信息带偏。

7 数据挖掘分析框架

在完整采集数据上, 分析目标不是简单排序模型, 而是解释模型行为在何种条件下发生系统性变化。本文把挖掘分析分为四类指标: 准确性、噪声翻转、层级一致性和失败模式。准确性回答模型是否给出与参考标签一致的最终判断; 噪声翻转关注相同空间参数下非因果信息是否改变结论; 层级一致性比较 L1、L2、L3 三种表述是否诱发不同推理路径; 失败模式则尝试把错误回复归类为概念混淆、数值比较错误、忽视关键参数或无法给出确定判断。

这四类指标共同服务于行为解释。若某个模型在 L3 上公式使用率很高但准确率下降, 说明形式化表达可

能诱发了错误建模; 若某个模型在 `ambient_noise` 或 `emotional_pressure` 下翻转率升高, 说明它把安全风险或情绪线索错误地并入了几何判断; 若错误类别集中在 `concept_confusion`, 则需要回看原始回复, 判断模型是否混淆了转弯半径、车体长度和平台进深之间的关系。

正式分析产出五类表格: 策略层级准确率、策略噪声翻转率、策略层级一致性、策略失败模式和采集覆盖率。其中覆盖率表是进入结果解释前的必要质量检查: 只有当每个 `strategy × model × repeat` 组合都达到预期样本量时, 跨模型和跨策略比较才具有可解释性。

8 结论与讨论

本文把一个具体的轮椅转弯判断问题转化为大语言模型行为挖掘任务, 形成了从 Prompt 设计、API 采集、断点续跑、特征构建到挖掘指标的完整协议。该协议的价值在于把模型的空间推理能力拆解为可观察的行为维度, 而不是只用单个总体准确率概括模型表现。

本研究仍有两点限制。第一, 参考标签采用简化几何余量规则, 适合作为行为测试参照, 但不能替代真实无障碍设计规范或动力学仿真。第二, 实验以文本 Prompt 为输入, 观察的是语言模型在参数化描述中的空间判断行为, 而不是多模态感知或真实机器人控制能力。基于完整 54,000 条记录, 本文的分析框架能够比较模型族差异、识别稳定失效模式, 并结合典型原始回复解释模型如何在常识、公式和无关背景之间切换。




图 3. 实验矩阵的张量化组织方式。Prompt 侧由策略、描述层级和扰动条件共同定义，采集侧再乘以模型集合与重复采样次数，从而把静态题目集合扩展为可按多维条件切分的模型行为记录。

表 2. 上游 Prompt 场景生成策略总览

策略	方法类别	实验目的
hash_baseline	哈希基线	复现原始 20 个场景的确定性采样结果，作为扩展策略的对照。
latin_hypercube_coverage	拉丁超立方	均匀覆盖五个几何变量的取值区间。
halton_space_filling	低差异序列	生成确定性但非规则的空间填充样本。
orthogonal_array_interactions	正交表	覆盖主效应与部分二阶交互。
fractional_factorial_effects	分数因子设计	以高低水平组合估计关键尺寸因素的方向性效应。
d_optimal_balanced_subset	候选池最优子集	在标签平衡约束下选择代表性样本。
dimensionless_ratio_design	无量纲比例	通过 W/w 、 D/R 、 R/L 等比例检验模型是否理解相对尺度。
metamorphic_counterfactual_pairs	反事实配对	每两条只改变一个关键参数，检验模型判断单调性。
constraint_boundary_solver	边界约束求解	反向生成靠近阈值的临界场景。
conflicting_cue_adversarial	对抗线索	构造宽度和转弯半径互相冲突的样本。
real_world_archetype_matrix	现实原型矩阵	按旧住宅楼、教学楼、医院、办公楼等原型组织尺寸。
rounding_threshold_ladder	取整阈值阶梯	围绕常见整数尺寸测试取整和常识锚定偏差。

表 3. 本轮 API 实验 Prompt 来源

来源	条数	角色
baseline	300	原始基线。
real_world_archetype_matrix	300	现实建筑原型。
halton_space_filling	300	参数空间填充。
dimensionless_ratio_design	300	相对尺度与比例关系。
constraint_boundary_solver	300	临界边界样本。
合计	1500	分层主样本。

表 4. 本轮实验模型集合

模型	说明
gpt-4o	原始对比模型。
gpt-4o-mini	原始轻量对比模型。
claude-3-5-sonnet-latest	原始 Claude 对比模型。
deepseek-chat	原始 DeepSeek 对比模型。
gpt-5.5	新增强模型。
claude-opus-4-6	新增强模型。
claude-sonnet-4-6-thinkin	新增推理增强模型。
g	
gemini-3-flash-preview	新增 Gemini 对比模型。
grok-4	新增 Grok 对比模型。
deepseek-v4-pro	新增 DeepSeek 强模型。
qwen3-max	新增 Qwen 强模型。
Kimi-K2-Thinking	新增 Kimi 推理模型。

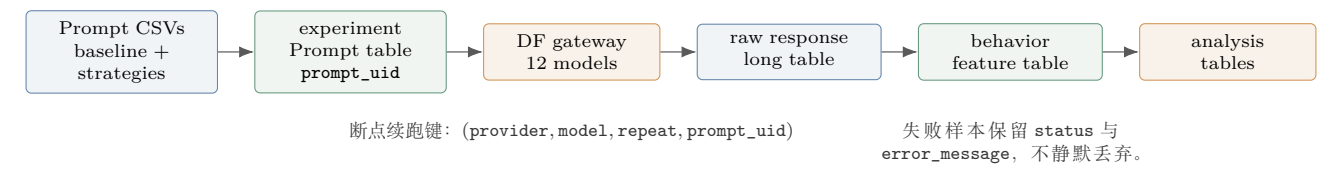


图 4. 多模型行为数据采集管线。上游 Prompt 文件首先合并为带有全局唯一键的实验主表，随后经 DF/OpenAI-compatible 网关调用多个模型，最终形成同时保留原始回复、结构化特征和失败记录的长表数据。

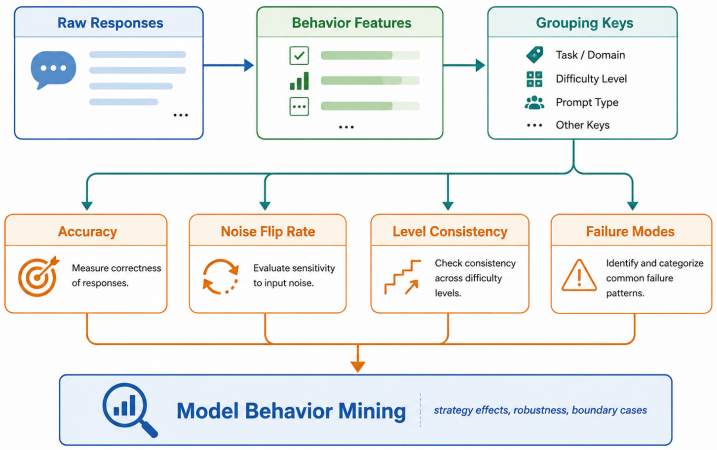


图 5. 行为数据挖掘框架。原始回复先被解析为结构化特征，再按策略、层级、扰动和模型分组，最终从准确性、噪声翻转、层级一致性和失败模式四个角度解释模型空间推理行为。

表 5. 实验采集输出文件

路径	用途
data/experiment_prompts.csv	合并后的实验 Prompt 主表。
data/raw/model_responses_experiment.csv	多模型 API 原始回复表。
data/processed/behavior_features_experiment.csv	从回复中抽取的行为特征表。
outputs_experiment/	策略、模型、扰动和层级统计结果。

表 6. 原始回复表核心字段

字段	含义
strategy, prompt_uid	Prompt 来源与全局唯一标识。
provider, model, repeat	API 网关、模型名称和重复编号。
collected_at	回复采集时间。
temperature, max_tokens, seed	调用参数。
status, error_message	成功或失败状态及错误信息。
latency_seconds	单次调用延迟。
response	模型完整原始回复。

参考文献

- [1] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D. Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901, 2020. URL <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfcb4967418bfb8ac142f64a-Abstract.html>.
- [2] Iulia Comsa and Srini Narayanan. A benchmark for reasoning with spatial prepositions. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 16328–16335, Singapore, 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.1015. URL <https://aclanthology.org/2023.emnlp-main.1015/>.
- [3] Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. Measuring massive multitask language understanding. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=d7KBjmI3GmQ>.
- [4] Robin Jia and Percy Liang. Adversarial examples for evaluating reading comprehension systems. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 2021–2031, Copenhagen, Denmark, 2017. Association for Computational Linguistics. doi: 10.18653/v1/D17-1215. URL <https://aclanthology.org/D17-1215/>.
- [5] Marco Tulio Ribeiro, Tongshuang Wu, Carlos Guestrin, and Sameer Singh. Beyond accuracy: Behavioral testing of NLP models with CheckList. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4902–4912, Online, 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.442. URL <https://aclanthology.org/2020.acl-main.442/>.
- [6] Aarohi Srivastava, Abhinav Rastogi, Abhishek Rao, Abu Awal Md Shoeb, Abubakar Abid, Adam Fisch, Adam R. Brown, Adam Santoro, Aditya Gupta, Adrià Garriga-Alonso, et al. Beyond the imitation game: Quantifying and extrapolating the capabilities of language models. *arXiv preprint arXiv:2206.04615*, 2022. URL <https://arxiv.org/abs/2206.04615>.
- [7] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. *arXiv preprint arXiv:2201.11903*, 2022. doi: 10.48550/arXiv.2201.11903. URL <https://arxiv.org/abs/2201.11903>.

A 补充材料

A.1 完整实验文件组织

完整实验以长表形式保存，核心文件包括合并后的 Prompt 主表、原始模型回复表、行为特征表和统计输出目录。表 7 汇总了复现实验与复查结果时最重要的文件。

表 7. 完整实验的主要文件

文件或目录	说明
data/experiment_prompts.csv	1500 条 Prompt 的统一主表，包含 strategy 和 prompt_uid。
data/raw/model_responses_experiment.csv	54,000 条模型调用记录，保留完整原始回复和失败信息。
data/processed/behavior_features_experiment.csv	从原始回复抽取的结构化行为特征表。
outputs_experiment/	按策略、层级、扰动、模型和重复编号生成的统计表。

A.2 覆盖率与一致性检查

在解释任何模型差异前，首先检查 collection_coverage.csv。对每个 strategy × model × repeat 组合，期望样本数为 300；对每个模型，期望总样本数为 1500 × 3 = 4500。若某个模型存在权限错误、限流或长时间超时，应先在覆盖率表中标记，再决定是否进入跨模型比较。

第二个必要检查是重复键唯一性。原始回复表中不应出现重复的

(provider,model,repeat,prompt_uid)

组合。该约束保证断点续跑不会把不同策略下相同 prompt_id 的样本混在一起。

A.3 结果解读原则

正式结果解释遵循三个原则。第一，准确率必须和层级、策略、扰动条件一起报告，避免单一总分掩盖临界样本或噪声样本上的系统性失败。第二，失败模式需要回到原始回复验证，不能只依赖关键词规则。第三，涉及无障碍安全的表述只用于模型行为分析，不能被解释为真实建筑设计或通行安全建议。